



MACHINE LEARNIG CON R

Luis Felipe Guevara Urquizo

①

Objetivo General

Desarrollar **conocimientos generales** sobre los **enfoques y metodologías de machine learning con R**, por medio del uso de metodologías activas de aprendizaje como es el **learning by doing**, con la finalidad de extraer información relevante usando la rigurosidad científica de los **métodos** y aplicando **soluciones prácticas** a través del **software R** en el ámbito laboral.

2

datos

“Los números tienen una historia importante que contar. Dependen que ti, darles una voz”

Stephen Few

3

Objetivo Específico 1



Analizar los datos disponibles mediante las técnicas que comprende el análisis exploratorio de los mismos, así como las particularidades de cada herramienta estadística que se aplica (Feature Engineering)

Unidad 1

Introducción al
Machine Learning

Unidad 2

Preprocesamiento
y ajuste

UNIDAD 1

INTRODUCCIÓN AL MACHINE LEARNING

5

Contenidos

UNIDAD 1

INTRODUCCIÓN AL MACHINE LEARNING

1.
 - 1. Software R para modelación
 - 2. Repaso de tidyverse
 - 3. Revisión de fundamentos de modelación en R

6

INTRODUCCIÓN AL MACHINE LEARNING


- Introducción
- Software R para modelación

7

INTRODUCCIÓN AL MACHINE LEARNIG

INTRODUCCIÓN

¿Qué es Machine Learnig?



8

INTRODUCCIÓN AL MACHINE LEARNING


INTRODUCCIÓN

Machine Learning

(aprendizaje automático)

Acercamiento definición

- **Conjunto de algoritmos** que permiten **identificar patrones presentes en la data**, y que permiten **crear modelos representativos**
- **Memorizan patrones que estén presentes** en los datos. Se **asume** el **futuro** se comportará como en el **pasado**.
- Los **métodos de machine learning** son una **estrategia parcial** para extraer, entender y dar valor a los datos.



9

INTRODUCCIÓN AL MACHINE LEARNING

INTRODUCCIÓN

Machine Learning

Definiciones formales

- **Arthur Samuel(1959):** Campo de estudio que les otorga a los ordenadores la habilidad de aprender sin ser explícitamente programados.
- **Tom Mitchell (1998):** Un programa de computadora aprende de la experiencia **E** con respecto a algunas tareas **T**; si su desempeño en **T**, medido por **P**, mejora con la experiencia **E**.



10


INTRODUCCIÓN AL MACHINE LEARNING

INTRODUCCIÓN

Machine Learning

Aplicaciones destacadas

- Búsqueda web
- Correo electrónico no deseado (spam)
- Reconocimiento de voz
- Recomendaciones de productos
- Score de créditos
- Otros.



11

INTRODUCCIÓN AL MACHINE LEARNING

R para Modelación

Tidyverse

- Conjunto paquetes en R para ciencia de datos (importar, transformar, visualizar modelar y comunicar)
- Comparten nombres y estructuras
- Puede hacer más rápida la manipulación de datos

paquetes

- **ggplot2**
- **dplyr**
- tidyr
- readr
- purr
- tibble
- stringr
- forcats



12

INTRODUCCIÓN AL MACHINE LEARNING


R para Modelación

Tidyverse

Paquete dplyr: Manipulación de datos

funciones destacadas

- mutate ()
- selec()
- filter
- summarise()
- arrange()
- group by()



Paquete ggplot2: Graficación

UNIDAD 2

PREPROCESAMIENTO Y AJUSTES

Contenidos

UNIDAD 2 PREPROCESAMIENTO Y AJUSTES

2. {
1. Feature engineering
 2. Ajuste de Modelos
 3. Métricas de rendimiento
 4. Flujo de modelos

PREPROCESAMIENTO Y AJUSTES

PREPROCESAMIENTO Y AJUSTES


FEATURE ENGINEERING

Feature Engineering

(≈ingeniería de datos)

Acercamiento definición

- **Técnicas** de ingeniería para **trabajar** sobre los **atributos** (características, variables) del problema
- Los **atributos adecuados** pueden requerir: creación, selección, prueba y transformación de variables



Ajustar y transformar los datos brutos (data) para una mayor aportación de información


17

PREPROCESAMIENTO Y AJUSTES

FEATURE ENGINEERING

Características

- Afecta a variables y casos, particularmente a los segundos
- Extraer un **subconjunto** de casos coherente con el problema y su solución



- Ahorra recursos de máquina
- Mejora eficacia de los algoritmos

Paquetes R destacados (ecosistema tidymodels)

- **recipes:** sirve para el preprocesado de datos (feature engineering)

PREPROCESAMIENTO Y AJUSTES


AJUSTE DE MODELO

Características

- ~Aplicar al modelo uno o varios algoritmos (técnica) que permita solventar una problemática.

Paquetes R destacados (ecosistema tidymodels)

- **parsnip:** sirve para la definición de modelos




19

PREPROCESAMIENTO Y AJUSTES

MÉTRICAS DE RENDIMIENTO

Funcionamiento del modelo

- Identificar el funcionamiento del modelo con respecto a su objetivo (ej: clasificar) mediante la utilización de **métricas de rendimiento**



Paquetes R destacados (ecosistema tidymodels)

- yardstick:** sirve para calcular métricas del modelo

PREPROCESAMIENTO Y AJUSTES

MODELADO Y ANÁLISIS DE DATOS




Figura 1.3: Esquema del proceso de modelado típico.

21


PREPROCESAMIENTO Y AJUSTES

FLUJO DE TRABAJO

Flujo de trabajo

(workflow)


- Conjunto de pasos que inician desde el pre-procesamiento, el ajuste del modelo y posibles actividades de pos-procesamiento
- Ejemplo: Estimación con regresión lineal



PREPROCESAMIENTO Y AJUSTES

FLUJO DE TRABAJO

- **Ejemplo:** Estimación con regresión lineal



Paquetes R destacados (ecosistema tidymodels)

- **Workflow*:** sirve para combinar todos los pasos del preprocesado y modelado en un solo objeto.

Kuhn, M. y Silge J. (2021). Tidy Modeling with R

23

Objetivo Específico 2



Aplicar técnicas de regresión y clasificación

Unidad 3
Algoritmos de
regresión y
clasificación

UNIDAD 3

ALGORITMOS DE REGRESIÓN Y CLASIFICACIÓN

“Lo que no se mide no se puede mejorar”

(William Thomson Kelvin)

Contenidos

UNIDAD 3

ALGORITMOS DE REGRESIÓN Y DE CLASIFICACIÓN

3.

1. Algoritmos de regresión
2. Regresión lineal
 1. Validación
 2. Selección del mejor modelo
3. Algoritmos de clasificación
 1. Regresión logística
 2. Análisis discriminante
 3. Naive Bayesiano
 4. Máquina de Soporte Vectorial
 5. Evaluación de modelos de clasificación

ALGORITMOS DE REGRESIÓN

- Métodos supervisados

ALGORITMOS DE REGRESIÓN

ANÁLISIS DE REGRESIÓN

Consideraciones



Es un conjunto de métodos de *machine learning* que permiten predecir una variable de resultado, continua (y), basada en el valor de una o más variables predictoras (x)

- El **principal objetivo** es definir una **fórmula matemática** que defina (y) en función de (x)
- Cuando este **modelo es estadísticamente significativo**, es posible usarlo para predecir (y) con nuevos valores de (x)
- Es necesario evaluar el desempeño predictivo del modelo en nueva data mediante la utilización de métricas de desempeño

ALGORITMOS DE REGRESIÓN

ANÁLISIS DE REGRESIÓN

Consideraciones

Principales métricas de rendimiento

- **Raíz cuadrada de la media de los errores al cuadrado (RMSE):** Mide el error de predicción del modelo. Mientras **menor** sea el **RMSE mejor** modelo.
- **R cuadrado:** Representa ~representa la correlación al cuadrado entre entre los valores de resultado conocidos y los valores predichos por el modelo. **mayor R cuadrado mejor** modelo



ALGORITMOS DE REGRESIÓN

ANÁLISIS DE REGRESIÓN

Consideraciones

Flujo de trabajo resumido para este tipo de análisis

1. **Segmentar aleatoriamente la base de datos** en una base de entrenamiento y una base de testeo
2. **Construir el modelo** de regresión a partir de la base de entrenamiento
3. **Hacer predicciones** utilizando la base de testero y **evaluar las métricas de rendimiento** (utilizar también re-muestreo)



31

ALGORITMOS DE REGRESIÓN

ANÁLISIS DE REGRESIÓN

Variantes

- Regresión lineal simple
- Regresión lineal múltiple
 - Efecto aditivo, efecto interacción
 - predictores continuos y categóricos
- Regresión no lineal múltiple
 - Regresión polinomial
 - Regresión Spline
 - Regresión modelos aditivos generalizados (GAM)

ALGORITMOS DE REGRESIÓN


REGRESIÓN LINEAL

Características

Regresión lineal:

Se asume una relación lineal entre la variable de resultado y las variables predictoras

$$y = a + bx$$




33

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Ajuste datos




34

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Ajuste datos



Residuos al cuadrado


$$\begin{aligned}\hat{y} &= b_0 + b_1 x & b_0 &= 10 \\ \hat{y} &= b_0 + (0)x & & \\ \hat{y} &= b_0 & \hat{y} &= 10\end{aligned}$$

35

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Mínimos cuadrados ordinarios



Reducir SSR

$$\min \sum (y_i - \hat{y}_i)^2$$

36

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Mínimos cuadrados ordinarios

$$\left. \begin{matrix} x_1, y_1 \\ \vdots \\ x_i, y_i \\ \vdots \\ x_n, y_n \end{matrix} \right\} y = \alpha + \beta x + \varepsilon$$

$$\left. \begin{matrix} y_1 = \alpha + \beta x_1 + \varepsilon_1 \\ y_i = \alpha + \beta x_i + \varepsilon_i \\ y_n = \alpha + \beta x_n + \varepsilon_n \end{matrix} \right\}$$

n ecuaciones y 2 incógnitas (α, β): **Incompatible**:
"no existe una solución que satisfaga todas las ecuaciones"

↓
 ε

n+2 incógnitas: **Compatible – indeterminado**:
infinitas posibles soluciones

$$\begin{matrix} \alpha=0 \\ \beta=0 \\ \varepsilon_i = y_i \end{matrix}$$

$$\text{Min} \sum \varepsilon^2 \longrightarrow \beta$$

$$\alpha = \bar{y} - \beta \bar{x}$$

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Mínimos cuadrados ordinarios

Del modelo lineal simple: $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$

de donde: $\varepsilon_i = y_i - \beta_0 - \beta_1 x_i$

elevando al cuadrado: $\sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$

Según el método de mínimos cuadrados, los estimadores de β_0 y β_1 debe satisfacer las ecuaciones:

$$\frac{\partial}{\partial \beta_0} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 = 0$$

$$\frac{\partial}{\partial \beta_1} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 = 0$$

Al derivar se obtiene un sistema de dos ecuaciones denominadas “ecuaciones normales”:

$$\sum_{i=1}^n y_i = n\beta_0 + \beta_1 \sum_{i=1}^n x_i$$

$$\beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

38

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Mínimos cuadrados ordinarios

$$\beta = \frac{Cov(x, y)}{Var(x)}$$

Coeficientes



$$\alpha = \bar{y} - \beta \bar{x}$$

39

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Mínimos cuadrados ordinarios

Bill vs Tip Amount (\$)

$$\hat{y}_i = 0.1462x - 0.8188$$

Coeficientes
interpretación

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Mínimos cuadrados ordinarios

Coeficientes
interpretación


- Modelo lineal logarítmico:
 - Interpretación: si x aumenta un 1%, $\hat{y}$ se incrementará en $(\hat{\beta}_2 / 100)$ unidades.
- Modelo logarítmico lineal:
 - Interpretación: si x aumenta en una unidad, entonces $\hat{y}$ se incrementará un $100 \times \hat{\beta}_2 \%$.
- Modelo doblemente logarítmico:
 - Interpretación: si x aumenta en 1%, entonces $\hat{y}$ se incrementará un $\hat{\beta}_2 \%$.

41

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Comparación modelos



$$SST = \sum (y_i - \bar{y})^2 = SSE$$


$$SST = \sum (y_i - \bar{y})^2 \neq SSE = \sum (y_i - \hat{y})^2$$

42

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

R2



$$r^2 = \frac{SSR}{SST}$$

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Validación (hipótesis Gauss – Markov)

$$E[\hat{\alpha}] = \alpha$$

$$E[\hat{\beta}] = \beta$$

$$\sqrt{\widehat{Var}(\hat{\alpha})} = \frac{\hat{\sigma}^2 \sum x_i^2}{n \sum x_i^2 - (\sum x_i)^2}$$

$$\sqrt{\widehat{Var}(\hat{\beta})} = \frac{n \hat{\sigma}^2}{n \sum x_i^2 - (\sum x_i)^2}$$

$$\hat{\sigma}^2 = SCR/n-2$$

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Contraste de Hipótesis

Contrastes individuales

Hipótesis nula

$$H_0 : \beta_j = k$$

$$H_A : \beta_j \neq k$$

Estadístico

$$t^* = \frac{\hat{\beta}_j - k}{\sqrt{\text{Var}(\hat{\beta}_j)}} \xrightarrow{H_0} t_{n-(k+1)}$$

Regla de decisión

$$RH_0 \text{ si } |t^*| > t_{n-(k+1), \alpha/2}$$

Prueba t

(significancia estadística individual de coeficientes)

Prueba F

(significancia estadística global de coeficientes)

ALGORITMOS DE REGRESIÓN

REGRESIÓN LINEAL

Hipótesis de Gauss - Markov

$$1) E[\varepsilon_i] = 0 \quad \forall X_i \longrightarrow E(\varepsilon'X) = 0$$

$$2) Var[\varepsilon_i] = \sigma^2 \quad \forall X_i$$

$$3) Cov[\varepsilon_i, \varepsilon_j] = 0 \quad \forall i \neq j$$

$$4) Cov[x_i, x_j] = 0 \quad \forall x_i \neq x_j$$

ALGORITMOS DE CLASIFICACIÓN

- Métodos supervisados

ALGORITMOS DE CLASIFICACIÓN

CLASIFICACIÓN

Consideraciones

Es un conjunto de métodos de *machine learning* que permiten predecir una variable de resultado, **categorica** (y), basada en el valor de una o más variables predictoras (x)

Principales técnicas de clasificación (supervisadas)

- Regresión logística
- Análisis discriminante
- Clasificados Naive Bayesiano
- Máquina vectorial de soporte



ALGORITMOS DE CLASIFICACIÓN

REGRESIÓN LOGÍSTICA

Características

Regresión logística:

- Es utilizada para predecir una clase (categoría) de los individuos basada en una varias variables predictoras.
- Se utiliza generalmente una variable de resultado binaria.
- Pertenece a la línea de los modelos lineales generalizados (GLM)
- La regresión logística no retorna directamente los valores de la variable categórica o de clase. Esta estima la probabilidad de pertenecer a una de las categorías

49

ALGORITMOS DE CLASIFICACIÓN

REGRESIÓN LOGÍSTICA


Características

Regresión logística:

$$p = \frac{e^y}{1 + e^y}$$

$p(\text{evento}=1|\mathbf{x})$: es la probabilidad de ocurrencia del evento de interés

Ratios odds: Cociente entre la probabilidad de poseer una característica y la de no poseerla.



50

ALGORITMOS DE CLASIFICACIÓN

REGRESIÓN LOGÍSTICA

Interpretación

Ejemplo: Clasificación de crédito

Step		B	S.E.	Wald	df	Sig.	Exp(B)
1	R.EDAD			19.121	4	.001	
	R.EDAD(1)	.977	.495	3.899	1	.048	2.655
	R.EDAD(2)	.447	.457	.956	1	.328	1.563
	R.EDAD(3)	.233	.462	.254	1	.614	1.262
	R.EDAD(4)	-.631	.515	1.504	1	.220	.532
	N.INSTRU			7.746	3	.052	
	N.INSTRU(1)	1.759	.838	4.408	1	.036	5.808
	N.INSTRU(2)	1.131	.480	5.552	1	.018	3.097
	N.INSTRU(3)	.847	.474	3.198	1	.074	2.332
	EST.CIV			15.507	4	.004	
	EST.CIV(1)	.511	.203	6.325	1	.012	1.667
	EST.CIV(2)	-.846	.373	5.134	1	.023	.429
	EST.CIV(3)	-.470	.687	.467	1	.494	.625
	EST.CIV(4)	-.015	.546	.001	1	.978	.985
	NOM.PROD			37.432	2	.000	
	NOM.PROD(1)	-1.043	.816	1.634	1	.201	.353
	NOM.PROD(2)	3.084	.520	35.234	1	.000	21.840
	P.CALIFH			138.467	4	.000	
	P.CALIFH(1)	-21.577	1375.386	.000	1	.987	.000
	P.CALIFH(2)	-2.909	.262	123.608	1	.000	.055
	P.CALIFH(3)	-1.695	.237	51.086	1	.000	.184
	P.CALIFH(4)	-.611	.269	5.176	1	.023	.543
	R.PLAZO			2.276	3	.517	
	R.PLAZO(1)	.472	.801	.348	1	.555	1.604
	R.PLAZO(2)	.718	.800	.806	1	.369	2.051
	R.PLAZO(3)	.444	.803	.305	1	.581	1.559
	Constant	-1.735	1.023	2.880	1	.090	.176

$$\text{Prob.} \left(\begin{matrix} \text{ser} \\ \text{malo} \end{matrix} \right) = \frac{e^{-1.735 + 0.977R.EDAD(1) + 0.447R.EDAD(2) + 0.233R.EDAD(3) - 0.631R.EDAD(4) + 1.759N.INSTRU(1) + 1.131N.INSTRU(2) + 0.847N.INSTRU(3) + 0.511EST.CIV(1) - 0.846EST.CIV(2) - 0.470EST.CIV(3) - 0.015EST.CIV(4) - 1.043NOM.PROD(1) + 3.084NOM.PROD(2) - 21.577P.CALIFH(1) - 2.909P.CALIFH(2) - 1.695P.CALIFH(3) - 0.611P.CALIFH(4) + 0.472R.PLAZO(1) + 0.718R.PLAZO(2) + 0.444R.PLAZO(3)}}{1 + e^{-1.735 + 0.977R.EDAD(1) + 0.447R.EDAD(2) + 0.233R.EDAD(3) - 0.631R.EDAD(4) + 1.759N.INSTRU(1) + 1.131N.INSTRU(2) + 0.847N.INSTRU(3) + 0.511EST.CIV(1) - 0.846EST.CIV(2) - 0.470EST.CIV(3) - 0.015EST.CIV(4) - 1.043NOM.PROD(1) + 3.084NOM.PROD(2) - 21.577P.CALIFH(1) - 2.909P.CALIFH(2) - 1.695P.CALIFH(3) - 0.611P.CALIFH(4) + 0.472R.PLAZO(1) + 0.718R.PLAZO(2) + 0.444R.PLAZO(3)}}$$

18-25 años
2.66 veces + riesg.
> 55 años

Solteros
1.67 veces + riesg.
Casados

a. Variable(s) entered on step 1: R.EDAD, N.INSTRU, EST.CIV, NOM.PROD, P.CALIFH, R.PLAZO.

51

ALGORITMOS DE CLASIFICACIÓN

REGRESIÓN LOGÍSTICA

Contraste de Hipótesis

Contrastes individuales

Hipótesis nula

$$H_0 : \beta_j = k$$

$$H_A : \beta_j \neq k$$

Estadístico

$$t^* = \frac{\hat{\beta}_j - k}{\sqrt{\text{Var}(\hat{\beta}_j)}} \xrightarrow{H_0} t_{n-(k+1)}$$

Regla de decisión

$$RH_0 \text{ si } |t^*| > t_{n-(k+1), \alpha/2}$$

Test de wald / z
(significancia estadística individual de coeficientes)

Prueba Chi 2
(significancia estadística global de coeficientes)

ALGORITMOS DE CLASIFICACIÓN

REGRESIÓN LOGÍSTICA

Supuestos Logit

- El resultado es binario o dicotómico
- Existe relación lineal entre el logit de la variable resultado (Y) y las variables predictoras(x)
- No hay influencia específica de valores particulares
- No hay multicolinealidad



ALGORITMOS DE CLASIFICACIÓN

ANÁLISIS DISCRIMINANTE

Características

Análisis discriminante:

- Es utilizada para predecir la probabilidad de pertenecer a una clase o categoría en función de una o múltiples variables predictoras.
- Comparado con el modelo logit, es más adecuado para predecir una categoría con más de dos opciones de respuesta (también es más estable).

ALGORITMOS DE CLASIFICACIÓN

ANÁLISIS DISCRIMINANTE

Características

Tipos de análisis discriminante:

- Análisis discriminante lineal
- Análisis discriminante cuadrático
- Análisis discriminante mixto
- Análisis discriminante flexible
- Análisis discriminante regularizado

ALGORITMOS DE CLASIFICACIÓN

ANÁLISIS DISCRIMINANTE

Análisis discriminante lineal

- Utiliza combinaciones lineales de los predictores para predecir la clase de una observación determinada.
- Supone que las variables predictoras (p) están distribuidas normalmente y las clases tienen varianzas idénticas (para análisis univariante, $p = 1$) o matrices de covarianza idénticas (para análisis multivariado, $p > 1$)

ALGORITMOS DE CLASIFICACIÓN

NAIVE BAYESIANO

Características

NAIVE BAYESIANO

- Es un método simple pero poderoso para solventar problemas de clasificación binaria o multiclase
- Predice la probabilidad de pertenencia a una clase utilizando el teorema de Bayes (probabilidad condicional, es decir, la probabilidad de que suceda algo, dado que ya ha ocurrido algo más).

57

ALGORITMOS DE CLASIFICACIÓN

NAIVE BAYESIANO

Probabilidad posterior (Bayes)

$$P(A|R) = \frac{P(R|A)P(A)}{P(R)}$$

$P(A)$: Probabilidad de A

$P(R|A)$: Probabilidad de que se de R dado A

$P(R)$: Probabilidad de R

$P(A|R)$: Probabilidad posterior de que se de A dado R


58

ALGORITMOS DE CLASIFICACIÓN

NAIVE BAYESIANO

Ejemplo Algoritmo Naive Bayes

¿a quién se vio pasar?



ALGORITMOS DE CLASIFICACIÓN

MÁQUINA VECTORIAL DE SOPORTE

Características

Support Vector Machine (SVM)



- Técnica de aprendizaje automático que se utiliza para tareas de clasificación.
- SVM identifica el límite de decisión óptimo que separa los puntos de datos de diferentes grupos (o clases) y luego predice la clase de nuevas observaciones basado en el límite de separación.
- Dependiendo de las situaciones, los diferentes grupos pueden ser separables por límites de clase lineales o no lineales.
- Se utiliza el truco de kernel (no lineales).

60

ALGORITMOS DE CLASIFICACIÓN

MÁQUINA VECTORIAL DE SOPORTE

Características



hiperplano de separación máxima

Objetivo Específico 3

Realizar agrupación de datos mediante el uso de la técnica K-medias para determinar conglomerados y valores atípicos.

Unidad 4
APRENDIZAJE
ESTADÍSTICO
DE MAQUINA

Unidad 5
CLASIFICACIÓN
NO
SUPERVISADA

Unidad 6
HERRAMIENTAS
PARA MODELOS
EFECTIVOS

UNIDAD 4

APRENDIZAJE ESTADÍSTICO DE MAQUINA

“Se cometen muchos menos errores usando datos inadecuados que cuando no se utilizan datos.”

Charles Babbage (1792-1871)

Contenidos

UNIDAD 4

APRENDIZAJE ESTADÍSTICO DE MÁQUINA

4.

- 1. K – Vecino más cercano
- 2. Árboles de decisión
- 3. Remuestreo agregado (Bagging)
- 4. Boosting

65

APRENDIZAJE ESTADÍSTICO DE MAQUINA

K – VECINO MÁS CERCANO

Consideraciones

$$NN(K, x_{\varphi})$$



Es un método no paramétrico de clasificación y regresión (sencillo)

La salida del algoritmo es la pertenencia a una clase.

Clasificación: Un objeto se clasifica de una determinada clase si la mayoría de sus vecinos pertenecen a esa clase

Regresión: Se estima un valor de una propiedad del objeto (media de la distancia)

2 elementos destacados

- Cantidad de vecinos
- Distancia (Euclídea)

66

APRENDIZAJE ESTADÍSTICO DE MAQUINA


K – VECINO MÁS CERCANO

Ejemplo

¿Es rojo o azul el punto (4,3)? (k=7, distancia euclídea)



Rojos	Azules
(1, 1)	(1, 4)
(1, 2)	(1, 7)
(2, 4)	(2, 2)
(2, 5)	(2, 7)
(3, 1)	(2, 8)
(3, 3)	(3, 4)
(4, 2)	(3, 6)
(4, 5)	(4, 4)
(4, 7)	(4, 6)
(5, 2)	(5, 4)
(5, 3)	(5, 5)
(6, 3)	(5, 8)
(7, 1)	(6, 4)
(7, 4)	(6, 5)
	(7, 5)



Fuente: SOLDAI, inteligencia artificial

67

APRENDIZAJE ESTADÍSTICO DE MAQUINA

K – VECINO MÁS CERCANO

Ejemplo

¿Es rojo o azul el punto (4,3)? (k=7, distancia euclídea)



Rojos	Distancia	Azules	Distancia
(1, 1)	3.605551275	(1, 4)	3.16227766
(1, 2)	3.16227766	(1, 7)	5
(2, 4)	2.236067977	(2, 2)	2.236067977
(2, 5)	2.828427125	(2, 7)	4.472135955
(3, 1)	2.236067977	(2, 8)	5.385164807
(3, 3)	1	(3, 4)	1.414213562
(4, 2)	1	(3, 6)	3.16227766
(4, 5)	2	(4, 4)	1
(4, 7)	4	(4, 6)	3
(5, 2)	1.414213562	(5, 4)	1.414213562
(5, 3)	1	(5, 5)	2.236067977
(6, 3)	2	(5, 8)	5.099019514
(7, 1)	3.605551275	(6, 4)	2.236067977
(7, 4)	3.16227766	(6, 5)	2.828427125
		(7, 5)	3.605551275

$$d(p, q) = \sqrt{(p_1 - q_1)^2 + (p_2 - q_2)^2 + \dots + (p_i - q_i)^2 + \dots + (p_n - q_n)^2}$$

El punto (4,3) es rojo

68

APRENDIZAJE ESTADÍSTICO DE MAQUINA

K – VECINO MÁS CERCANO

Consideraciones adicionales

- Excelente frente a pocas dimensiones
- Los datos requieren ser normalizados
- Se puede complementar con técnicas de reducción de dimensiones



APRENDIZAJE ESTADÍSTICO DE MAQUINA

ÁRBOL DE DECISIÓN

Consideraciones

Idea clave

Es una estructura de árbol similar a un diagrama de flujo donde un nodo interno representa una característica (o atributo), la rama representa una regla de decisión y cada nodo hoja representa el resultado.

A diferencia de los modelos lineales, mapean bastante bien las relaciones no lineales

Elementos destacados

- A partir del nodo raíz, el algoritmo aprende a particionar en función del valor del atributo.
- Divide el árbol de una manera recursiva llamada partición recursiva



70


APRENDIZAJE ESTADÍSTICO DE MAQUINA

ÁRBOL DE DECISIÓN

Estructura

Medidas de selección de atributos (ASM)

- Gini
- Entropía
- Información gain




71

APRENDIZAJE ESTADÍSTICO DE MAQUINA

ÁRBOL DE DECISIÓN

Flujo de funcionamiento




72

APRENDIZAJE ESTADÍSTICO DE MAQUINA

ÁRBOL DE DECISIÓN

Algoritmo

Identificar la especie (mamífero / reptil)



APRENDIZAJE ESTADÍSTICO DE MAQUINA

REMUESTREO AGREGADO (**Baggin**) (Bootstrap aggregation)

Consideraciones

El *Bagging* pretende reducir el error de aprendizaje con la implementación de un conjunto de algoritmos de machine learning homogéneos (combatir sesgo y varianza).


Idea clave

Uso de múltiples bases de aprendizaje que están siendo entrenadas por separado a partir de muestras aleatorias derivada del set de entrenamiento. A partir de un enfoque de promedios se busca la obtención de un modelo más estable y exacto (accuracy).

2 elementos destacados

- Muestreo aleatorio con reemplazo (bootstrapping)
- Conjunto homogéneo de algoritmos de machine learning (esemble learning)

Bagging




74

APRENDIZAJE ESTADÍSTICO DE MAQUINA

REMUESTREO AGREGADO (Baggin) (Bootstrap aggregation)

Flujo funcionamiento




75

APRENDIZAJE ESTADÍSTICO DE MAQUINA

REMUESTREO AGREGADO (**Baggin**) (Bootstrap aggregation)

Consideraciones adicionales

- El *baggin* se ejecuta en paralelo.
- Se requiere mayor número de *subsets* para problemas de clasificación que para problemas de regresión
- Conjuntos pequeños de datos requieren pocos estimadores.
- Conjuntos grandes de datos requieren un mayor número de estimadores



APRENDIZAJE ESTADÍSTICO DE MAQUINA

BOOSTING

Consideraciones


El *Boosting* pretende mejorar la estabilidad y la efectividad de un modelo de *Machine Learning*, mediante la generación de hipótesis secuenciales, donde se busca mejorar o corregir la anterior.

Idea clave

Es la implementación secuencial de un algoritmo homogéneo de *Machine Learning*, con la finalidad de mejorar la estabilidad del modelo, tratando los errores cometidos por el algoritmo de forma previa.

Diferenciador

- La forma en que se trata a los errores para mejorarlos secuencialmente es el diferenciador de cada técnica asociada



77

APRENDIZAJE ESTADÍSTICO DE MAQUINA

BOOSTING

Técnicas de Boosting


errores

- AdaBoost (Adaptive Boosting)
- Gradient Boosting
- XGBoost (Extreme Gradient Boosting)

Vector de pesos

Optimiza función
de pérdidas

Secuencia
árboles
de
decisión



78

APRENDIZAJE ESTADÍSTICO DE MAQUINA

BOOSTING

Flujo funcionamiento

AdaBoost

